

1 Wprowadzenie

2 Warstwa konwolucyjna


Warstwa konwolucyjna jest podstawowym budulcem modeli, które są wykorzystywane przez nas w tym projekcie: ResNet-ów (eng. Residual Networks) oraz sieci InceptionTime. Wykorzystywana jest ona przede wszystkim do pracy nad obrazami, ale może być również stosowana przy przetwarzaniu sygnałów, takich jak sygnały EKG badane przez nas. Warstwy te posiadają wiele zalet, które sprawiają, że są one idealnym wyborem do pracy z naszymi danymi. Przede wszystkim, w przeciwieństwie do warstw gęstych (warstwy w sieciach MLP), pozwalają one na wzięcie pod uwagę lokalnych zależności danych wejściowych, co jest kluczowe przy pracy z sygnałem takim jak EKG. Ponadto, warstwy te mają znacznie mniej parametrów, co pozwala na szybsze uczenie, a także zmniejsza ryzyko przeuczenia modelu.

Warstwa konwolucyjna opiera się jak sama nazwa wskazuje na operacji konwolucji. W jedynym wymiarze, operacja ta polega na przekształceniu wektora wejściowego x w wektor wyjściowy y , tak że każdy element y_i jest obliczany jako iloczyn skalarny fragmentu wektora wejściowego x z wektorem wag w , który jest przesuwany po całym wektorze wejściowym. Wzór na obliczenie elementu y_i wygląda następująco:

$$y_i = \sum_{j=0}^{k-1} w_j x_{i+j} \quad (1)$$

Gdzie $[w_0, w_1, \dots, w_{k-1}]^T$ to wektor wag, a k to rozmiar jądra konwolucyjnego (ang. kernel size).

Spójrzmy sobie teraz na parametry warstwy konwolucyjnej, które będziemy wykorzystywać w dalszej części.



Rysunek 1: Parametry warstwy konwolucyjnej. Źródło: adaptacja rysunku z [3, s. 164].

- **Kernel size** - rozmiar jądra konwolucyjnego, czyli długość wektora wag, który jest przesuwany po wektorze wejściowym. Różna długość jądra pozwala na wychwycenie bardziej lokalnych (mały rozmiar jądra) lub bardziej globalnych (duży rozmiar jądra) zależności
- **Stride** - ten parametr określa o ile pozycji wektora wejściowego przesuwane jest jądro konwolucyjne podczas obliczania kolejnych elementów wektora wyjściowego
- **Padding** - ten parametr określa, czy i ile zer jest dodawanych do wektora wejściowego na początku i końcu. Pozwala on zachować rozmiar wektora wyjściowego równy rozmiarowi wektora wejściowego (bo zarówno kernel size, jak i stride mogą powodować zmniejszenie tego rozmiaru)

- **Channels (In oraz Out)** - parametr ten określa liczbę kanałów wejściowych oraz wyjściowych. Liczba kanałów wejściowych określa, ile różnych wektorów wejściowych jest przetwarzanych przez warstwę. Natomiast liczba kanałów wyjściowych określa, ile różnych wektorów wyjściowych jest generowanych przez warstwę. Liczba wag, dla danej warstwy jest równa $kernel_size \times in_channels \times out_channels$

3 ResNet18

Jednym z największych problemów w uczeniu sieci konwolucyjnych jest problem znikającego gradientu (ang. vanishing gradient). Polega on na tym, że podczas uczenia sieci, propagowane gradienty stają się coraz mniejsze, co prowadzi do tego, że w końcu stają się zbyt małe, aby mogły skutecznie aktualizować wagi sieci. Problem ten zapobiega budowaniu naprawdę głębokich sieci konwolucyjnych, które są w stanie uczyć się złożonych reprezentacji danych.

Rozwiązanie tego problemu zostało zaproponowane w pracy [1]. Autorzy zaproponowali architekturę sieci, w której podzielili sieć na bloki, które mają połączenia rezydualne (wektor wejściowy jest dodawany do wektora wyjściowego bloku). Połączenia te pozwalają na propagowanie gradientów przez sieć, co zapobiega problemowi jego zanikania. Znane są różne warianty tej architektury, które różnią się liczbą bloków oraz liczbą warstw (co można zaobserwować na Rysunku 2).

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9


Rysunek 2: Różne warianty architektury ResNet. [1]

W naszym projekcie wykorzystaliśmy wariant ResNet18, ponieważ jest on stosunkowo mały, co pozwala na szybsze uczenie, a jednocześnie zapobiega przeczcuczeniu modelu. Przyjrzyjmy się bliżej tej architekturze. Na początku sieci znajduje się warstwa konwolucyjna, która służy do wstępnego przetworzenia danych wejściowych. Następnie znajduje się warstwa MaxPooling, która służy do zmniejszenia rozmiaru danych. Po niej znajdują się 4 bloki, które składają się z dwóch warstw konwolucyjnych wraz z batch normalization oraz funkcją aktywacji ReLU. W każdej z tych warstw znajduje się wspomniane wcześniej połączenie rezydualne. Na samym końcu sieci znajduje się warstwa global average pooling, która służy do zamiany wektora z każdego kanału na pojedynczą wartość, a następnie warstwa gęsta, która będzie służyła do klasyfikacji danych (w naszym przypadku mamy tylko jedną klasę, bo jest to problem binarnej klasyfikacji).

4 InceptionTime Network

Po przeanalizowaniu architektury ResNet18, przyjrzyjmy się teraz sieci InceptionTime, która jest architekturą specjalnie zaprojektowaną do pracy z przebiegami czasowymi. Architektura ta została zaproponowana w pracy [2] i opiera się w głównej mierze na trzech warstwach konwolucyjnych, o różnej długości jądra konwolucyjnego, które są połączone równolegle. Pozwala to na wychwycenie zarówno lokalnych, jak i globalnych zależności w danych wejściowych. Możemy rozpatrywać architekturę InceptionTime Network na trzech poziomach szczegółowości. Na najwyższym poziomie, sieć składa się z dwóch bloków

połączonych szeregowo. Każdy z tych bloków składa się z trzech warstw InceptionModule, które są połączone znowu szeregowo. Natomiast najciekawsze jest to, co dzieje się na najniższym poziomie, czyli w samym module InceptionModule.



Rysunek 3: Budowa InceptionModule.

Jak widać na Rysunku 3, centralną częścią tego modułu są trzy warstwy konwolucyjne o różnych rozmiarach jądra konwolucyjnego (w pracy są to odpowiednio 10, 20 i 40, natomiast w naszej implementacji są to odpowiednio 9, 19 i 39, tak aby nie pojawiały się problemy z paddingiem). Zauważmy również, że podobnie jak w ResNet, mamy tutaj połączenie rezydualne, z podobnego powodu, czyli aby zapobiec problemowi znikającego gradientu. Oprócz tego, należy zauważyć obecność dwóch warstw bottleneck, które służą do dopasowania liczby kanałów wejściowych i wyjściowych. Należy zauważyć, że architektura tej sieci czerpie z pomysłów znanych z ResNet, ale je znacząco rozwija w obrębie pojedynczego bloku.

5 Trening i wyniki dla sieci ResNet18 oraz InceptionTime


Trenowanie sieci ResNet18 oraz InceptionTime zostało przeprowadzone na zbiorze Code-15 + SamiTrop, gdzie proporcje podziału na zbiór treningowy, walidacyjny oraz testowy wynosiły odpowiednio 70%, 15% oraz 15%. Dla obydwu modeli wykorzystaliśmy tę samą funkcję straty, czyli binary cross-entropy, ale ze zmodyfikowaną wagą dla pozytywnych etykiet, która została ustawiona na stosunek liczby negatywnych etykiet do liczby pozytywnych etykiet w zbiorze treningowym. Zrobiliśmy tak, aby poradzić sobie z problemem niezbalansowania etykiet w naszym zbiorze danych (pozytywne etykiety stanowią tylko około 2% wszystkich). Ponadto wykorzystaliśmy optymalizator Adam z wartością współczynnika uczenia się równą 10^{-4} oraz weight_decay równym 10^{-3} . Dodatkowo dla każdego z modeli przeprowadziliśmy eksperymenty z wykorzystaniem metadanych (znormalizowany wiek, płeć oraz wskaźnik, czy EKG zostało określone w zbiorze jako poprawne) oraz z wykorzystaniem augmentacji danych (w 20 % przypadków wyzerowany jeden kanał EKG, a w 50% przypadków dodany szum gaussowski z odchyleniem równym 0.05). Każdy z modeli był trenowany przez 25 epok, z uwzględnieniem wczesnego zatrzymania, jeśli przez 5 kolejnych epok nie zwiększała się wartość AUPRC na zbiorze walidacyjnym. Następnie każdy z modeli był testowany na zbiorze testowym, czego wyniki można zobaczyć w Tabeli 1.

name	best_val_auprc	test_auroc	test_auprc	test_acc	duration
resnet18	0.178	0.807	0.160	0.775	18 min 0 s
resnet18_meta	0.171	0.811	0.162	0.759	18 min 2 s
resnet18_meta_aug	0.171	0.806	0.159	0.780	28 min 27 s
inception	0.205	0.806	0.171	0.793	58 min 18 s
inception_meta	0.201	0.816	0.159	0.756	46 min 34 s
inception_meta_aug	0.202	0.818	0.170	0.836	69 min 22 s

Tabela 1: Wyniki treningu i testu dla sieci ResNet18 oraz InceptionTime.

Na Rysunku 4 widać krzywe uczenia dla poszczególnych modeli. Należy ponadto zauważyć, że żaden z

modeli nie był trenowany przez całe 25 epok, bo wcześniej został zatrzymany przez mechanizm wczesnego zatrzymania.



Rysunek 4: Krzywe Precision-Recall dla sieci ResNet18 oraz InceptionTime.


Z Tabeli 1 oraz Rysunku 4 widać, że najlepsze wyniki osiągnęły sieci InceptionTime, oraz przede wszystkim, że były one dużo bardziej odporne na przetrenowanie niż sieci ResNet18. Wynika to najprawdopodobniej z faktu, że architektura InceptionTime posiada mniej parametrów niż architektura ResNet18, co przy bardzo małej liczbie pozytywnych etykiet w naszym zbiorze danych pozwalało na lepsze uogólnianie modelu. Ostatecznie należy zauważyć, że najlepszy wynik osiągnęła sieć InceptionTime bez metadanych i augmentacji. Dodanie metadanych mogło zaburzyć proces uczenia, zwłaszcza, że było ich bardzo mało, i najprawdopodobniej nie są one skorelowane z występowaniem choroby Chagasa. Natomiast dodanie augmentacji danych mogło spowodować zbyt duże zaburzenie danych wejściowych. Wydaje mi się, że to co mogłem zrobić lepiej w tym przypadku, to zamiast modyfikować dane wejściowe, mógłbym dodać nowe dane z wykorzystaniem augmentacji, które byłyby modyfikacją danych już obecnych. Mogłoby to pozwolić na lepsze uogólnienie przy braku utraty informacji.

Następnie, postanowiliśmy stworzyć ensemble z 5 modeli InceptionTime (jest to pomysł zaczerpnięty bezpośrednio z pracy [2]). Wyniki tego eksperymentu można zobaczyć w Tabeli 2.

name	best_val_auprc	test_auroc	test_auprc	test_acc	duration
seed_42	0.206	0.815	0.170	0.714	45 min 18 s
seed_43	0.192	0.810	0.166	0.739	45 min 14 s
seed_44	0.196	0.815	0.160	0.755	36 min 48 s
seed_45	0.198	0.812	0.162	0.759	36 min 48 s
seed_46	0.198	0.804	0.168	0.733	54 min 10 s
ensemble	–	0.825	0.184	0.759	220 min 35 s

Tabela 2: Wyniki treningu i testu dla poszczególnych seedów oraz zespołu.

Ponadto na Rysunku 5 można zobaczyć krzywe uczenia dla poszczególnych seedów tego ensemblingu.



Rysunek 5: Krzywe uczenia dla poszczególnych seedów ensembleingu.

Zauważmy, że wyniki ensembleingu są lepsze niż wyniki poszczególnych seedów o 0.015 w AUPRC, co jest znaczącą poprawą. Zinterpretujmy teraz wyniki całego ensembleingu. Nasz ensembleing osiągnął wynik 0.184 w AUPRC, co przy procencie pozytywnych etykiet 0.024 oznacza, że model przewiduje pozytywne etykiety 7.67 razy lepiej niż losowy klasyfikator.

Literatura

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [2] Hassan Ismail Fawaz, Benjamin Lucas, Germain Forestier, Charlotte Pelletier, Daniel F Schmidt, Jonathan Weber, Geoffrey I Webb, Lhassane Idoumghar, Pierre-Alain Muller, and François Petitjean. Inceptiontime: Finding alexnet for time series classification. *Data mining and knowledge discovery*, 34(6):1936–1962, 2020.
- [3] Simon JD Prince. *Understanding deep learning*. MIT press, 2023.